E-book de Introdução ao R

William Cordeiro, Lucas de Freitas...

Table of contents

Apresentação 4

I ENTREGAVEL 1 5

1 Entregável 1 — Importação da PNAD Contínua no Positron 6

2 Importação da PNAD Contínua no Positron 7
- 2.1 Etapa 1 — Instalar o pacote . . . 7
- 2.2 Etapa 2 — Carregar o pacote . . . 7
- 2.3 Etapa 3 — Definir os parâmetros da consulta . . . 8
- 2.4 Etapa 4 — Baixar e importar a PNAD Contínua . . . 8
- 2.5 Etapa 5 — Conferir o resultado . . . 8
- 2.6 Encerramento . . . 9

II ENTREGAVEL 2 10

3 Introdução e interpretação das variáveis: Conhecendo os microdados da PNAD Contínua 11
- 3.1 O que são variáveis e por que precisamos interpretá-las? . . . 11
- 3.2 O que é um dicionário de variáveis? . . . 11
  - 3.2.1 Como ler um dicionário de variáveis? . . . 12
- 3.3 Tipos de variáveis e unidades de medida . . . 12
  - 3.3.1 Variáveis qualitativas . . . 13
  - 3.3.2 Variáveis quantitativas . . . 13
  - 3.3.3 Unidades de medida . . . 13
- 3.4 Aplicando os conceitos à nossa pesquisa . . . 14
- 3.5 Explorando as variáveis no R . . . 15
  - 3.5.1 Passo 2 — Consultar uma variável específica . . . 15
  - 3.5.2 Passo 3 — Consultar os códigos e suas categorias . . . 16
  - 3.5.3 Passo 4 — Identificar a pessoa responsável pelo domicílio . . . 16
- 3.6 Cuidados metodológicos antes de prosseguir . . . 17
  - 3.6.1 Unidade de observação . . . 17
  - 3.6.2 Valores ausentes e códigos especiais . . . 17
  - 3.6.3 Rendimentos nominais e reais . . . 17

3.6.4 Pesos amostrais 17

III ENTREGAVEL 3 **23**

Apresentação

Bem-vindo ao nosso e-book de introdução à linguagem R.

Este material foi desenvolvido em colaboração para ensinar programação em R, desde os conceitos básicos.

Part I

ENTREGAVEL 1

1 Entregável 1 — Importação da PNAD Contínua no Positron

2 Importação da PNAD Contínua no Positron

Neste entregável, vamos aprender a instalar e carregar o pacote `PNADcIBGE`, selecionar o ano e o trimestre de interesse, importar os dados da PNAD Contínua e verificar o resultado no R usando o Positron.

Exemplo didático: primeiro trimestre de 2024.

Pré-requisitos: R instalado, Positron, conexão com a internet e espaço disponível em disco.

> **Sobre a geração do PDF:** por padrão, os blocos deste capítulo são **exibidos, mas não executados** durante a renderização. Isso evita downloads grandes e falhas por falta de internet. Depois de instalar o pacote e confirmar que a importação funciona no Positron, você pode trocar `eval: false` por `eval: true` no início deste arquivo para executar o código e incluir seus resultados no PDF.

2.1 Etapa 1 — Instalar o pacote

O pacote `PNADcIBGE` permite acessar dados da PNAD Contínua a partir do R. A instalação precisa ser feita apenas se o pacote ainda não estiver instalado.

```
install.packages("PNADcIBGE")
```

Dica: execute esse comando no console R do Positron uma vez; não é necessário reinstalar o pacote a cada sessão.

2.2 Etapa 2 — Carregar o pacote

Em uma nova sessão do R, carregue o pacote instalado com `library()`.

```
library(PNADcIBGE)
```

2.3 Etapa 3 — Definir os parâmetros da consulta

Antes de buscar os dados, defina o ano e o trimestre que deseja consultar. No R, o operador `<-` atribui um valor a um objeto.

```
ano <- 2024
trimestre <- 1  # valores válidos: 1, 2, 3 ou 4
```

Neste exemplo, estamos solicitando o **primeiro trimestre de 2024**. Para consultar outro período, modifique esses dois valores.

2.4 Etapa 4 — Baixar e importar a PNAD Contínua

A função `get_pnadc()` é utilizada para obter os dados. O operador `::` indica explicitamente o pacote ao qual a função pertence. A opção `design = TRUE` solicita um objeto com informações do desenho amostral da pesquisa.

```
pnad <- PNADcIBGE::get_pnadc(
  year = ano,
  quarter = trimestre,
  design = TRUE
)
```

Atenção: a primeira execução pode demorar, porque envolve download de dados. É preciso ter internet e espaço no disco.

2.5 Etapa 5 — Conferir o resultado

Depois da importação, confira a classe do objeto, seu resumo, os nomes das variáveis, as dimensões da base e as primeiras observações.

```
class(pnad)                  # classe do objeto importado
summary(pnad)                # resumo do desenho amostral
names(pnad$variables)[1:20]  # primeiras 20 variáveis
dim(pnad$variables)           # número de linhas e colunas
head(pnad$variables)         # primeiras observações
```

Esses comandos ajudam a verificar a estrutura do objeto importado antes de iniciar as análises.

2.6 Encerramento

Neste capítulo, você viu o fluxo básico de importação da PNAD Contínua no Positron: **instalar o pacote → carregá-lo → definir o período → importar → conferir os dados**. Os exemplos usam o primeiro trimestre de 2024; o procedimento pode ser adaptado para outros trimestres.

Part II

ENTREGAVEL 2

3 Introdução e interpretação das variáveis: Conhecendo os microdados da PNAD Contínua

3.1 O que são variáveis e por que precisamos interpretá-las?

Antes de iniciar qualquer análise estatística, é necessário compreender quais informações estão disponíveis na base de dados e o que cada uma delas representa.

Uma variável é uma característica observada para cada unidade de análise de uma pesquisa. Na PNAD Contínua, por exemplo, podemos encontrar informações sobre idade, escolaridade, rendimento, condição de ocupação e características dos domicílios.

Em uma pesquisa sobre diferenças de renda entre famílias chefiadas por homens e mulheres, algumas perguntas orientam a escolha das variáveis:

- Qual é a renda do domicílio?
- Quem é considerado responsável pelo domicílio?
- Em qual região do Brasil o domicílio está localizado?
- Qual é a escolaridade dos moradores?
- Quantas pessoas compõem o domicílio?

Cada pergunta precisa ser associada a uma ou mais variáveis disponíveis na base de dados.

Uma observação importante: não basta encontrar uma variável com um nome aparentemente adequado. É necessário verificar sua definição, população de referência, período de coleta, categorias de resposta e unidade de medida.

3.2 O que é um dicionário de variáveis?

Um dicionário de variáveis é um documento que descreve as informações presentes em uma base de dados. Ele funciona como um guia para compreender e utilizar corretamente cada variável.

Normalmente, apresenta informações como: Nome da variável, descrição, tipo de variável (numérica, categórica, textual), Categorias (valores ou respostas possíveis), unidade de medida e população de referência

Por exemplo, imagine que uma base apresente a variável V2009. Sem consultar a documentação, o pesquisador não sabe necessariamente o que esse código representa. Ao consultar o dicionário, descobre que se trata de uma informação sobre idade. Essa consulta permite compreender o significado dos dados e evita interpretações equivocadas.

Isso é importante pois:

- Evita confundir variáveis com nomes ou códigos semelhantes.
- Permite identificar quais informações são adequadas aos objetivos da pesquisa.
- Ajuda a reconhecer valores ausentes e categorias especiais.
- Facilita a interpretação dos resultados.
- Torna a análise reproduzível por outros pesquisadores.

3.2.1 Como ler um dicionário de variáveis?

Ao abrir o dicionário, você encontrará códigos que identificam as variáveis e suas respectivas descrições.

Código	Descrição
V2009	Idade do morador na data de referência
V2007	Sexo do morador
V2005	Condição no domicílio

Para interpretar corretamente essas informações, é necessário observar três elementos:

1. Código da variável: é o identificador utilizado no banco de dados e nos comandos do R.
2. Descrição: explica qual característica está sendo investigada.
3. Categorias ou valores possíveis: indicam como as respostas foram registradas.

Por exemplo, uma variável sobre sexo pode apresentar valores numéricos que representam categorias de resposta. O número não possui significado isoladamente: é a documentação que informa o que cada código representa.

3.3 Tipos de variáveis e unidades de medida

As variáveis podem assumir diferentes formatos, e reconhecer essas diferenças é essencial para escolher os procedimentos estatísticos adequados.

3.3.1 Variáveis qualitativas

Representam características ou categorias. Podem ser divididas em:

- Nominais: categorias sem uma ordem natural, como sexo, região geográfica e cor ou raça.
- Ordinais: categorias que apresentam uma ordem, como faixas de escolaridade ou classes de rendimento.

3.3.2 Variáveis quantitativas

Representam valores numéricos e podem ser divididas em:

- Discretas: assumem valores contáveis, como número de moradores no domicílio.
- Contínuas: podem assumir diferentes valores dentro de um intervalo, como rendimento mensal.

É importante não confundir o formato numérico de uma variável com seu significado estatístico. Uma variável que utiliza os números 1, 2, 3 e 4 para representar regiões brasileiras continua sendo qualitativa, pois os números são apenas códigos de identificação.

3.3.3 Unidades de medida

Também é necessário identificar a unidade em que cada característica é registrada.

Informação	Unidade de medida
Idade	Anos
Escolaridade	Anos de estudo ou nível de instrução
Rendimento	Reais (R$)
Número de moradores	Pessoas
Região	Categoria geográfica

Essa distinção é especialmente importante na análise de renda. Um rendimento mensal domiciliar total não representa a mesma coisa que um rendimento domiciliar per capita. O primeiro considera a renda total do domicílio; o segundo considera a renda em relação ao número de moradores, conforme a definição específica do indicador.

3.4 Aplicando os conceitos à nossa pesquisa

Agora que conhecemos os conceitos básicos, podemos identificar as variáveis necessárias para investigar diferenças de renda entre domicílios chefiados por homens e mulheres.

Para o nosso exercício, utilizaremos os microdados da PNAD Contínua de 2024, referentes à primeira visita domiciliar anual.

A seleção inicial de variáveis contempla:

Código	Informação investigada	Utilidade na pesquisa
UF	Unidade da Federação	Identificar a localização geográfica
V2001	Número de pessoas no domicílio	Analisar a composição domiciliar
V2003	Número de ordem do morador	Identificar registros individuais
V2005	Condição no domicílio	Identificar a pessoa responsável
V2007	Sexo do morador	Identificar o sexo da pessoa responsável
V2009	Idade	Caracterizar os moradores
VD3005	Anos de estudo	Investigar a escolaridade
VD5001	Indicador de rendimento domiciliar	Investigar a renda
VD5002	Indicador de rendimento domiciliar per capita	Investigar a renda por morador
VD5004	Indicador de rendimento domiciliar	Complementar a análise de renda
VD5005	Indicador de rendimento domiciliar per capita	Complementar a análise de renda

A tabela acima é uma seleção inicial de trabalho. As descrições completas de VD5001, VD5002, VD5004 e VD5005, inclusive a distinção entre rendimento efetivo e habitual e os critérios de inclusão de rendimentos, devem ser transcritas do dicionário específico da edição anual de 2024 antes da publicação do e-book. Não se deve tratar esses indicadores como equivalentes. Atenção: quem é considerado chefe do domicílio? Esse é um dos pontos metodológicos mais importantes da pesquisa.

A PNAD Contínua utiliza o conceito de pessoa responsável pelo domicílio. A variável V2005 identifica a relação de cada morador com essa pessoa.

Na documentação, o código 01 corresponde à pessoa responsável pelo domicílio. Assim, podemos identificar quem é responsável e, em seguida, consultar seu sexo por meio da variável V2007.

Isso significa que não devemos simplesmente classificar todos os moradores do sexo masculino como integrantes de domicílios chefiados por homens.

O procedimento correto é:

1. Identificar a pessoa responsável pelo domicílio.
2. Consultar o sexo dessa pessoa.
3. Classificar o domicílio de acordo com essa informação.

Outra ressalva conceitual: pessoa responsável pelo domicílio não é necessariamente sinônimo de chefe de família. Um domicílio pode conter mais de uma família. Portanto, é importante definir se a pesquisa pretende comparar domicílios ou famílias e manter essa unidade de análise ao longo do trabalho.

3.5 Explorando as variáveis no R

Até aqui, aprendemos a consultar a documentação. Agora vamos começar a relacionar essas informações com o banco de dados.

Como estamos utilizando o R, podemos verificar quais variáveis estão disponíveis e observar os valores registrados. ### Passo 1 — Carregar os dados No exemplo, consideramos que a base já foi carregada com o pacote PNADcIBGE, utilizando a função get_pnadc().

```r
# Visualizar a estrutura da base
str(dados_pnad)
```

```r
# Visualizar as primeiras observações
head(dados_pnad)
```

```r
# Consultar os nomes das variáveis
names(dados_pnad)
```

3.5.1 Passo 2 — Consultar uma variável específica

Vamos começar pela variável V2005, que identifica a condição do morador no domicílio.

```r
# Visualizar os valores registrados
table(dados_pnad$V2005, useNA = "ifany")
```

O comando table() apresenta a frequência de cada valor encontrado na variável.

O argumento useNA = “ifany” permite identificar se existem observações ausentes (NA).

3.5.2 Passo 3 — Consultar os códigos e suas categorias

Podemos utilizar os atributos da variável para verificar se os rótulos foram carregados junto com os dados:

```
# Consultar os atributos da variável
attributes(dados_pnad$V2005)
```

Se a variável possuir rótulos associados, eles poderão aparecer nos atributos.

Também podemos visualizar a distribuição de uma variável de interesse:

```
# Frequência por sexo
table(dados_pnad$V2007, useNA = "ifany")
```

Importante: a frequência dos códigos não substitui a consulta ao dicionário. É necessário verificar na documentação o significado de cada categoria antes de interpretar os resultados.

3.5.3 Passo 4 — Identificar a pessoa responsável pelo domicílio

Podemos utilizar a variável V2005 para identificar os registros correspondentes à pessoa responsável:

```
# Selecionar pessoas responsáveis
responsaveis <- dados_pnad |>
  dplyr::filter(V2005 == "01")
```

O exemplo pressupõe que a variável esteja armazenada como texto. Se estiver numérica, utilize V2005 == 1. Antes de executar, confira a classe da variável com class(dados_pnad$V2005).

A partir dessa seleção, podemos consultar a variável V2007 para identificar o sexo das pessoas responsáveis.

Esse será um dos primeiros passos para construir nossa classificação de domicílios chefiados por homens e mulheres.

3.6 Cuidados metodológicos antes de prosseguir

Antes de iniciar as análises, precisamos considerar alguns aspectos importantes.

3.6.1 Unidade de observação

Os microdados da PNAD Contínua apresentam registros individuais dos moradores. Isso significa que um mesmo domicílio pode aparecer em várias linhas, uma para cada morador.

Se o objetivo é comparar rendimentos domiciliares, precisamos tomar cuidado para não contabilizar o mesmo domicílio várias vezes.

3.6.2 Valores ausentes e códigos especiais

Algumas variáveis podem apresentar códigos que representam situações específicas, como informação ignorada ou não aplicável. Esses códigos não devem ser interpretados automaticamente como valores reais.

3.6.3 Rendimentos nominais e reais

Os valores monetários precisam ser interpretados considerando o período de referência. Se o objetivo for comparar rendimentos de diferentes anos, será necessário realizar o deflacionamento.

3.6.4 Pesos amostrais

A PNAD Contínua é uma pesquisa por amostragem probabilística. Portanto, para produzir estimativas representativas da população brasileira, é necessário considerar os pesos amostrais e o desenho da pesquisa. Não basta calcular médias simples dos registros e tratá-las como estimativas populacionais.

4

O broder vai delegar tarefa pro davi e ele ira desenvolver aqui

5

O broder vai delegar tarefa pro lucas e ele ira desenvolver aqui

6

O broder vai delegar tarefa pro mestre e ele ira desenvolver aqui

7

O broder vai delegar tarefa pro broder e ele ira desenvolver aqui

8

O broder vai delegar tarefa pro joão pedro e ele ira desenvolver aqui

Part III

ENTREGAVEL 3

9

O broder vai delegar tarefa pro davi e ele ira desenvolver aqui

10

11

O broder vai delegar tarefa pro joão pedro e ele ira desenvolver aqui

12

O broder vai delegar tarefa pro lucas e ele ira desenvolver aqui

13

14