E-book de Introdução ao R

William Cordeiro, Lucas de Freitas...

Table of contents

Apresentação 4

I ENTREGAVEL 1 5

1 Entregável 1 — Importação da PNAD Contínua no Positron 6

2 Importação da PNAD Contínua no Positron 7
2.1 Etapa 1 — Instalar o pacote . . . 7
2.2 Etapa 2 — Carregar o pacote . . . 8

3 Etapa 3 — Definir os parâmetros da consulta 9
3.1 Etapa 4 — Baixar e importar a PNAD Contínua . . . 9
3.2 Etapa 5 — Conferir o resultado . . . 10
3.2.1 1. Identificar o tipo de objeto — `class()` . . . 10
3.2.2 2. Consultar o resumo do objeto — `summary()` . . . 11
3.2.3 3. Conhecer os nomes das variáveis — `names()` . . . 11
3.2.4 4. Verificar o tamanho da base — `dim()` . . . 12
3.2.5 5. Visualizar os primeiros registros — `head()` . . . 12
3.2.6 Conclusão . . . 13
3.3 Encerramento . . . 13

II ENTREGAVEL 2 14

4 Introdução e interpretação das variáveis: Conhecendo os microdados da PNAD Contínua 15
4.1 O que são variáveis e por que precisamos interpretá-las? . . . 15
4.2 O que é um dicionário de variáveis? . . . 15
4.2.1 Como ler um dicionário de variáveis? . . . 16
4.3 Tipos de variáveis e unidades de medida . . . 16
4.3.1 Variáveis qualitativas . . . 17
4.3.2 Variáveis quantitativas . . . 17
4.3.3 Unidades de medida . . . 17
4.4 Cuidados metodológicos antes de prosseguir . . . 17
4.4.1 Unidade de observação . . . 18

4.4.2 Valores ausentes e códigos especiais . . . 18
4.4.3 Rendimentos nominais e reais . . . 18
4.4.4 Pesos amostrais . . . 18

5 Seleção das variáveis para a análise de renda 19
5.1 O que queremos investigar? . . . 19
5.2 Escolhendo as variáveis necessárias . . . 19
5.3 Por que escolhemos cada variável? . . . 20
5.3.1 Unidade da Federação: UF . . . 20
5.3.2 Número de pessoas no domicílio: V2001 . . . 21
5.3.3 Condição no domicílio: V2005 . . . 21
5.3.4 Sexo: V2007 . . . 21
5.3.5 Idade: V2009 . . . 22
5.4 Cor ou raça: V2010 . . . 22
5.4.1 Anos de estudo: VD3005 . . . 22
5.4.2 Condição em relação à força de trabalho: VD4001 . . . 22
5.4.3 Condição de ocupação: VD4002 . . . 23
5.4.4 Rendimento domiciliar: VD5001 . . . 23
5.4.5 Rendimento domiciliar per capita: VD5002 . . . 23
5.5 Como localizar as variáveis no R? . . . 24
5.5.1 Visualizando os nomes das variáveis . . . 24
5.5.2 Visualizando apenas as primeiras variáveis . . . 24
5.5.3 Procurando uma variável específica . . . 24
5.5.4 Verificando todas as variáveis selecionadas . . . 25
5.5.5 Identificando quais variáveis estão ausentes . . . 26
5.5.6 Verificando os tipos de dados . . . 26
5.6 Conferindo nossa seleção . . . 27

6 Renomeando as variáveis de forma padronizada e armazenando-as em uma base de dados para nossa pesquisa 28
6.1 Por que criar uma base de dados separada para nossa pesquisa? . . . 28
6.2 Por que padronizar os nomes das variáveis? . . . 29
6.2.1 Qual padrão de nomenclatura utilizar? . . . 29
6.3 Renomeando as variáveis para a base de dados da pesquisa . . . 30
6.3.1 Como renomear as variáveis com o R na prática? . . . 30
6.4 Resumo: Expandindo para nossa pesquisa e o resultado da padronização. . . . 31
6.5 Tabela de correspondência das variáveis . . . 31

7 Dicionário das variáveis selecionadas 33

III ENTREGAVEL 3 35

Apresentação

Bem-vindo ao nosso e-book de introdução à linguagem R.

Este material foi desenvolvido em colaboração para ensinar programação em R, desde os conceitos básicos.

Part I

ENTREGAVEL 1

1 Entregável 1 — Importação da PNAD Contínua no Positron

2 Importação da PNAD Contínua no Positron

Neste entregável, vamos aprender a instalar e carregar o pacote `PNADcIBGE`, selecionar o ano e o trimestre de interesse, importar os dados da PNAD Contínua e verificar o resultado no R usando o Positron.

Exemplo didático: primeiro trimestre de 2024.

Pré-requisitos: R e Positron instalados.

2.1 Etapa 1 — Instalar o pacote

Para começar, precisamos instalar o pacote `PNADcIBGE`, que permite acessar os microdados da PNAD Contínua diretamente pelo R.

```
1 install.packages("PNADcIBGE")
```

Mas de onde vem esse pacote?

No R, existem pacotes desenvolvidos por pesquisadores e programadores que acrescentam funcionalidades à linguagem. Muitos deles ficam disponíveis no **CRAN (Comprehensive R Archive Network)**, um repositório oficial de distribuição de pacotes do R, ou seja quando instalamos o R ele vem com a capacidade de acessar o CRAN pela internet.

O pacote `PNADcIBGE` foi desenvolvido para facilitar o acesso e o tratamento dos dados da PNAD Contínua, disponibilizados pelo IBGE, por isso, não precisamos acessar manualmente o site do IBGE para instalar esse pacote. O próprio R consegue encontrá-lo e instalá-lo pelo comando que usamos acima.

Entendendo o código:

- `install.packages()` é uma função do R utilizada para instalar pacotes.
- `"PNADcIBGE"` é o nome do pacote que queremos instalar.
- Ao executar o comando, o R acessa um repositório de pacotes configurado, como o CRAN, e realiza a instalação.

Dica: execute esse comando no console R do Positron apenas uma vez, pois não é necessário reinstalar o pacote a cada nova sessão.

Caso queira **salvar um código e, ao mesmo tempo, testá-lo**, escreva-o diretamente no editor de código do positron. Em seguida, selecione o código desejado e pressione **Ctrl + Enter**.

O Positron enviará o trecho selecionado para o console R, onde ele será executado. Dessa forma, você poderá testar comandos específicos sem precisar executar novamente todos os códigos que já escreveu, mantendo suas anotações salvas e organizadas.

2.2 Etapa 2 — Carregar o pacote

Em uma nova sessão do R, carregue o pacote instalado com `library()`.

```
1 library(PNADcIBGE)
```

A função library() carrega um pacote previamente instalado, disponibilizando suas funções para utilização na sessão atual do R. Diferentemente de install.packages(), ela não realiza uma nova instalação.

Podemos pensar no install.packages() como um "instalador de um jogo" e no library() como "abrir o jogo para começar a jogar".

3 Etapa 3 — Definir os parâmetros da consulta

Antes de buscar os dados, defina o ano e o trimestre que deseja consultar. No R, o operador <- atribui um valor a um objeto.

```
ano <- 2024
trimestre <- 1  # Trimestres disponíveis: 1, 2, 3 ou 4
```

Neste exemplo, estamos solicitando o **primeiro trimestre de 2024**. Para consultar outro período, modifique esses dois valores.

3.1 Etapa 4 — Baixar e importar a PNAD Contínua

Agora que definimos o ano e o trimestre, vamos utilizar a função get_pnadc() para baixar os microdados da PNAD Contínua diretamente do IBGE e importá-los para o R.

```
pnad <- PNADcIBGE::get_pnadc(
  year = ano,
  quarter = trimestre,
  design = TRUE
)
```

Entendendo cada parte do código:

pnad <-: cria um objeto chamado pnad, no qual serão armazenados os dados importados.

PNADcIBGE::: indica que estamos utilizando uma função do pacote PNADcIBGE. O operador :: permite acessar essa função sem precisar carregar o pacote com library().

get_pnadc(): é a função responsável por obter e importar os dados da PNAD Contínua.

year = ano: define o ano da pesquisa. Como anteriormente escrevemos ano <- 2024, serão utilizados os dados de 2024.

quarter = trimestre: define o trimestre. Como escrevemos trimestre <- 1, será utilizado o primeiro trimestre.

design = TRUE: solicita que os dados sejam organizados considerando o desenho amostral da PNAD, incluindo informações como pesos amostrais, importantes para produzir estimativas estatísticas adequadas à pesquisa.

Atenção: a primeira execução pode demorar, pois envolve o download e o processamento dos microdados. É necessário ter conexão com a internet e espaço disponível no computador.

3.2 Etapa 5 — Conferir o resultado

Após importar os dados da PNAD Contínua, precisamos verificar se a importação ocorreu corretamente e entender como as informações estão organizadas. Para isso, utilizaremos cinco comandos do R.

3.2.1 1. Identificar o tipo de objeto — `class()`

```
class(pnad)
```

A função `class()` identifica a classe de um objeto no R, determinando como ele está estruturado e quais métodos podem ser utilizados com ele.

Por exemplo, um objeto pode ser da classe `data.frame` (tabela de dados), `matrix` (matriz) ou `lm` (modelo de regressão).

Saída esperada:

```
[1] "svyrep.design"
```

No nosso caso, essa classe indica que os dados foram organizados em um objeto de desenho amostral com pesos de replicação, adequado para análises estatísticas que consideram a amostragem da PNAD.

Por que é importante? Porque permite verificar se o objeto foi criado no formato esperado e quais funções poderão ser utilizadas nas análises.

3.2.2 2. Consultar o resumo do objeto — `summary()`

```
summary(pnad)
```

A função `summary()` apresenta um resumo do objeto, mas as informações exibidas dependem de sua classe.

Por exemplo, para uma variável numérica, pode apresentar média, mediana, mínimo e máximo. Já para nosso objeto `pnad`, apresenta informações sobre o desenho amostral.

Exemplo ilustrativo simplificado de saída:

```
Call: PNADcIBGE::get_pnadc(...)

Survey design with replicate weights

Number of observations: ...
Replicate weights: ...
```

O formato e os detalhes efetivos podem ser diferentes. Os pontos representam informações que dependem da base importada.

Por que é importante? Porque ajuda a conferir a estrutura amostral utilizada, incluindo informações relacionadas aos pesos e às réplicas. Esse comando não calcula automaticamente a renda média da população.

3.2.3 3. Conhecer os nomes das variáveis — `names()`

```
names(pnad$variables)[1:20]
```

A função `names()` mostra os nomes das variáveis da base.

- `pnad$variables`: acessa a tabela de dados armazenada no objeto.
- `[1:20]`: seleciona os primeiros 20 nomes.

Exemplo ilustrativo de saída:

```
[1] "Ano"      "Trimestre" "UF"
[4] "UPA"      "Estrato"   "V1008"
[7] "V1014"    "V1022"     "V1023"
...
```

Essa lista é apenas um exemplo: os primeiros 20 nomes e sua ordem devem ser conferidos no seu console.

Por que é importante? Porque permite conhecer as variáveis disponíveis e identificar os códigos que serão utilizados no estudo.

3.2.4 4. Verificar o tamanho da base — `dim()`

```
dim(pnad$variables)
```

A função `dim()` informa o tamanho da tabela, retornando a quantidade de linhas e colunas.

Exemplo ilustrativo de saída:

```
[1] 480000  430
```

Nesse exemplo fictício:

- `480000`: quantidade de registros (linhas).
- `430`: quantidade de variáveis (colunas).

Os números reais dependerão da base importada.

Por que é importante? Porque permite conhecer o tamanho da base e verificar se existem observações e variáveis disponíveis para trabalhar.

3.2.5 5. Visualizar os primeiros registros — `head()`

```
head(pnad$variables)
```

A função `head()` apresenta, por padrão, as seis primeiras linhas da tabela, permitindo observar como os dados estão organizados.

Exemplo ilustrativo de saída (colunas selecionadas):

```
  UF V2007 V2009 V2010
1 35     1    25     1
2 35     2    32     4
3 33     1    41     2
4 33     2    28     1
5 31     1    54     4
6 31     2    37     2
```

Nesse exemplo fictício, cada linha representa um registro e cada coluna corresponde a uma variável. Os números podem representar quantidades ou códigos de categorias, dependendo da variável.

Por que é importante? Porque permite visualizar a organização dos dados, identificar possíveis valores ausentes (`NA`) e entender como as informações aparecem antes das análises.

3.2.6 Conclusão

Com esses cinco comandos, conseguimos verificar a classe do objeto, consultar sua estrutura amostral, identificar as variáveis, conhecer as dimensões da base e visualizar os primeiros registros.

Atenção: os resultados apresentados são exemplos didáticos. Ao executar os comandos no Positron, o leitor poderá encontrar valores e formatos diferentes, conforme os dados importados.

Essa conferência inicial nos prepara para o próximo capítulo, no qual aprenderemos a selecionar e interpretar as variáveis da PNAD Contínua.

3.3 Encerramento

Neste capítulo, você viu o fluxo básico de importação da PNAD Contínua no Positron: **instalar o pacote → carregá-lo → definir o período → importar → conferir os dados**. Os exemplos usam o primeiro trimestre de 2024; o procedimento pode ser adaptado para outros trimestres.

Part II

ENTREGAVEL 2

4 Introdução e interpretação das variáveis: Conhecendo os microdados da PNAD Contínua

4.1 O que são variáveis e por que precisamos interpretá-las?

Antes de iniciar qualquer análise estatística, é necessário compreender quais informações estão disponíveis na base de dados e o que cada uma delas representa.

Uma variável é uma característica observada para cada unidade de análise de uma pesquisa. Na PNAD Contínua, por exemplo, podemos encontrar informações sobre idade, escolaridade, rendimento, condição de ocupação e características dos domicílios.

Em uma pesquisa sobre diferenças de renda entre famílias chefiadas por homens e mulheres, algumas perguntas orientam a escolha das variáveis:

- Qual é a renda do domicílio?
- Quem é considerado responsável pelo domicílio?
- Em qual região do Brasil o domicílio está localizado?
- Qual é a escolaridade dos moradores?
- Quantas pessoas compõem o domicílio?

Cada pergunta precisa ser associada a uma ou mais variáveis disponíveis na base de dados.

Uma observação importante: não basta encontrar uma variável com um nome aparentemente adequado. É necessário verificar sua definição, população de referência, período de coleta, categorias de resposta e unidade de medida.

4.2 O que é um dicionário de variáveis?

Um dicionário de variáveis é um documento que descreve as informações presentes em uma base de dados. Ele funciona como um guia para compreender e utilizar corretamente cada variável.

Normalmente, apresenta informações como: Nome da variável, descrição, tipo de variável (numérica, categórica, textual), Categorias (valores ou respostas possíveis), unidade de medida e população de referência

Por exemplo, imagine que uma base apresente a variável V2009. Sem consultar a documentação, o pesquisador não sabe necessariamente o que esse código representa. Ao consultar o dicionário, descobre que se trata de uma informação sobre idade. Essa consulta permite compreender o significado dos dados e evita interpretações equivocadas.

Isso é importante pois:

- Evita confundir variáveis com nomes ou códigos semelhantes.
- Permite identificar quais informações são adequadas aos objetivos da pesquisa.
- Ajuda a reconhecer valores ausentes e categorias especiais.
- Facilita a interpretação dos resultados.
- Torna a análise reproduzível por outros pesquisadores.

4.2.1 Como ler um dicionário de variáveis?

Ao abrir o dicionário, você encontrará códigos que identificam as variáveis e suas respectivas descrições.

Código	Descrição
V2009	Idade do morador na data de referência
V2007	Sexo do morador
V2005	Condição no domicílio

Para interpretar corretamente essas informações, é necessário observar três elementos:

1. Código da variável: é o identificador utilizado no banco de dados e nos comandos do R.
2. Descrição: explica qual característica está sendo investigada.
3. Categorias ou valores possíveis: indicam como as respostas foram registradas.

Por exemplo, uma variável sobre sexo pode apresentar valores numéricos que representam categorias de resposta. O número não possui significado isoladamente: é a documentação que informa o que cada código representa.

4.3 Tipos de variáveis e unidades de medida

As variáveis podem assumir diferentes formatos, e reconhecer essas diferenças é essencial para escolher os procedimentos estatísticos adequados.

4.3.1 Variáveis qualitativas

Representam características ou categorias. Podem ser divididas em:

- Nominais: categorias sem uma ordem natural, como sexo, região geográfica e cor ou raça.
- Ordinais: categorias que apresentam uma ordem, como faixas de escolaridade ou classes de rendimento.

4.3.2 Variáveis quantitativas

Representam valores numéricos e podem ser divididas em:

- Discretas: assumem valores contáveis, como número de moradores no domicílio.
- Contínuas: podem assumir diferentes valores dentro de um intervalo, como rendimento mensal.

É importante não confundir o formato numérico de uma variável com seu significado estatístico. Uma variável que utiliza os números 1, 2, 3 e 4 para representar regiões brasileiras continua sendo qualitativa, pois os números são apenas códigos de identificação.

4.3.3 Unidades de medida

Também é necessário identificar a unidade em que cada característica é registrada.

Informação	Unidade de medida
Idade	Anos
Escolaridade	Anos de estudo ou nível de instrução
Rendimento	Reais (R$)
Número de moradores	Pessoas
Região	Categoria geográfica

Essa distinção é especialmente importante na análise de renda. Um rendimento mensal domiciliar total não representa a mesma coisa que um rendimento domiciliar per capita. O primeiro considera a renda total do domicílio; o segundo considera a renda em relação ao número de moradores, conforme a definição específica do indicador.

4.4 Cuidados metodológicos antes de prosseguir

Antes de iniciar as análises, precisamos considerar alguns aspectos importantes.

4.4.1 Unidade de observação

Os microdados da PNAD Contínua apresentam registros individuais dos moradores. Isso significa que um mesmo domicílio pode aparecer em várias linhas, uma para cada morador.

Se o objetivo é comparar rendimentos domiciliares, precisamos tomar cuidado para não contabilizar o mesmo domicílio várias vezes.

4.4.2 Valores ausentes e códigos especiais

Algumas variáveis podem apresentar códigos que representam situações específicas, como informação ignorada ou não aplicável. Esses códigos não devem ser interpretados automaticamente como valores reais.

4.4.3 Rendimentos nominais e reais

Os valores monetários precisam ser interpretados considerando o período de referência. Se o objetivo for comparar rendimentos de diferentes anos, será necessário realizar o deflacionamento.

4.4.4 Pesos amostrais

A PNAD Contínua é uma pesquisa por amostragem probabilística. Portanto, para produzir estimativas representativas da população brasileira, é necessário considerar os pesos amostrais e o desenho da pesquisa. Não basta calcular médias simples dos registros e tratá-las como estimativas populacionais.

5 Seleção das variáveis para a análise de renda

5.1 O que queremos investigar?

Antes de selecionar as variáveis, precisamos definir o objetivo da análise.

Neste exemplo, nosso objetivo é investigar se existe diferença de renda entre domicílios chefiados por mulheres e por homens.

Podemos formular algumas perguntas:

- Domicílios chefiados por mulheres têm renda diferente dos chefiados por homens?
- A renda domiciliar per capita varia conforme a idade da pessoa responsável?
- A escolaridade da pessoa responsável está associada à renda do domicílio?
- A renda varia entre os estados brasileiros?
- O número de moradores altera a comparação entre renda total e renda per capita?

Para responder a essas perguntas, precisamos identificar as variáveis correspondentes na PNAD Contínua.

5.2 Escolhendo as variáveis necessárias

Para nossa análise, selecionaremos inicialmente as seguintes variáveis:

Código	Nome padronizado	Descrição	Tipo	Nível
UF	uf	Unidade da Federação	Qualitativa nominal	Domicílio
V2001	numero_moradores	Número de pessoas no domicílio	Quantitativa discreta	Domicílio
V2005	condicao_domicilio	Condição do morador em relação à pessoa responsável	Qualitativa nominal	Pessoa

Código	Nome padronizado	Descrição	Tipo	Nível
V2007	sexo	Sexo do morador	Qualitativa nominal	Pessoa
V2009	idade	Idade em anos completos	Quantitativa discreta	Pessoa
V2010	cor_raca	Cor ou raça declarada	Qualitativa nominal	Pessoa
VD3005	anos_estudo	Anos de estudo (pessoas de 5 anos ou mais), em categorias ordenadas	Qualitativa ordinal	Pessoa
VD4001	condicao_forca_trabalho	Condição em relação à força de trabalho	Qualitativa nominal	Pessoa
VD4002	condicao_ocupacao	Condição de ocupação (só para quem está na força de trabalho)	Qualitativa nominal	Pessoa
VD5001	renda_domiciliar	Rendimento domiciliar, em R$ (completar com o dicionário de 2024)	Quantitativa contínua	Domicílio
VD5002	renda_per_capita	Rendimento domiciliar per capita, em R$	Quantitativa contínua	Domicílio

Essas variáveis constituem uma seleção inicial para o estudo.

A escolha definitiva deverá considerar a população que queremos analisar e a documentação correspondente ao período da pesquisa.

5.3 Por que escolhemos cada variável?

5.3.1 Unidade da Federação: UF

A variável `UF` identifica a Unidade da Federação em que o domicílio está localizado.

Ela permite comparar a renda entre estados brasileiros. Isso é importante porque os mercados de trabalho e as condições econômicas variam entre regiões, e essas diferenças podem influenciar a comparação entre domicílios chefiados por homens e por mulheres.

5.3.2 Número de pessoas no domicílio: V2001

A variável `V2001` informa quantas pessoas compõem o domicílio.

Ela é importante porque a renda total de um domicílio não tem o mesmo significado para uma pessoa que mora sozinha e para uma família com cinco moradores. Com essa informação, conseguimos analisar a composição domiciliar e entender a diferença entre renda total e renda por morador.

5.3.3 Condição no domicílio: V2005

A variável `V2005` identifica a relação de cada morador com a pessoa responsável pelo domicílio.

Na documentação, o código `01` corresponde à pessoa responsável. Por isso, ela é a variável-chave para identificar quem será considerado a chefia do domicílio na nossa pesquisa.

É importante lembrar que pessoa responsável pelo domicílio não é, necessariamente, sinônimo de chefe de família, pois um mesmo domicílio pode conter mais de uma família. Nesta pesquisa, a unidade de análise é o **domicílio**, e essa definição deve ser mantida ao longo de todo o trabalho.

5.3.4 Sexo: V2007

A variável `V2007` identifica o sexo registrado na pesquisa.

Ela não deve ser usada isoladamente para classificar os domicílios. Não podemos classificar todos os moradores do sexo masculino como integrantes de domicílios chefiados por homens. O procedimento correto é:

1. Identificar a pessoa responsável pelo domicílio (`V2005`).
2. Consultar o sexo dessa pessoa (`V2007`).
3. Classificar o domicílio de acordo com essa informação.

Assim, `V2005` e `V2007` são usadas em conjunto para construir a variável central da nossa análise.

5.3.5 Idade: V2009

A variável `V2009` registra a idade do morador, em anos completos.

A idade da pessoa responsável é relevante porque a renda tende a variar ao longo do ciclo de vida. Posteriormente, poderemos organizar as idades em faixas etárias para realizar comparações e usá-las como característica de controle.

5.4 Cor ou raça: V2010

A variável `V2010` representa a Cor ou raça dos moradores dos domicílios pesquisados, que pode ser branca, preta, amarela, parda ou indígena.

Ela é o controle mais usado em estudos de desigualdade de renda no Brasil. A diferença entre domicílios chefiados por mulheres e por homens pode ser em parte uma diferença racial, e sem essa variável a comparação fica incompleta.

5.4.1 Anos de estudo: VD3005

A variável `VD3005` informa os anos de estudo das pessoas de 5 anos ou mais de idade.

A escolaridade é uma característica importante nas análises de renda, pois está associada às oportunidades no mercado de trabalho. Ao observar a escolaridade da pessoa responsável, poderemos verificar se uma eventual diferença de renda entre os domicílios persiste quando comparamos pessoas com níveis de estudo semelhantes.

Os anos de estudo são organizados em categorias ordenadas. Por isso, devemos conferir no dicionário como a variável está codificada antes de utilizá-la.

5.4.2 Condição em relação à força de trabalho: VD4001

A variável `VD4001`classifica as pessoas em idade de trabalhar em dois grupos: as que estão na força de trabalho (trabalhando ou procurando trabalho) e as que estão fora dela (por exemplo, aposentados, estudantes e pessoas que cuidam de afazeres domésticos).

Ela é importante porque nos permite conhecer a situação da pessoa responsável pelo domicílio diante do mercado de trabalho. Como `VD4001` cobre tanto quem está na força de trabalho quanto quem está fora dela, é a variável mais adequada para descrever a situação de toda a população de pessoas responsáveis, sem perder casos.

Ela também é a base para a variável seguinte, `VD4002`, que detalha a situação de quem está na força de trabalho.

5.4.3 Condição de ocupação: VD4002

A variável `VD4002`informa se a pessoa que está na força de trabalho está ocupada ou desocupada.

Ela deve ser usada com cuidado, porque só é preenchida para pessoas na força de trabalho. Para quem está fora dela, como aposentados e pensionistas, o valor aparece como `NA` (informação ausente). Esses `NA` não indicam erro nos dados: significam que a pergunta não se aplica àquela pessoa.

Isso é relevante para a nossa pesquisa, pois muitas pessoas responsáveis por domicílios estão fora da força de trabalho. Se filtrarmos ou analisarmos apenas os registros com `VD4002` preenchida, podemos excluir parte importante dos domicílios e alterar a comparação entre os chefiados por mulheres e por homens.

Por isso, usaremos `VD4002` em conjunto com `VD4001`: a segunda mostra quem está dentro ou fora da força de trabalho, e a primeira detalha a situação de quem está dentro.

5.4.4 Rendimento domiciliar: VD5001

A variável `VD5001` é um indicador de **rendimento domiciliar**, isto é, relaciona-se à renda do domicílio como um todo, e não à renda de uma pessoa específica.

Ela será uma das principais variáveis da pesquisa, pois representa a informação que queremos comparar entre domicílios chefiados por homens e por mulheres.

É importante observar que esse rendimento **não se limita ao rendimento do trabalho de quem chefia o domicílio**: ele reúne os rendimentos dos moradores, de acordo com os critérios de inclusão definidos pelo IBGE. A descrição completa, inclusive o tipo de rendimento considerado (habitual ou efetivo) e quais moradores ficam de fora do cálculo, deve ser conferida no dicionário da edição utilizada.

5.4.5 Rendimento domiciliar per capita: VD5002

A variável `VD5002` é o indicador de **rendimento domiciliar per capita**, ou seja, o rendimento do domicílio em relação ao número de moradores, conforme a definição do IBGE.

Ela é importante porque um rendimento domiciliar total não representa a mesma coisa que um rendimento por morador. Dois domicílios com a mesma renda total podem ter condições de vida muito diferentes se tiverem números diferentes de moradores.

Por isso, `VD5001` e `VD5002` não devem ser tratadas como equivalentes: a primeira mede a renda total do domicílio, e a segunda, a renda por morador. Em nossa análise, poderemos compará-las para verificar se as conclusões mudam conforme o indicador escolhido.

5.5 Como localizar as variáveis no R?

Agora que escolhemos as variáveis necessárias, precisamos verificar se elas estão disponíveis na base importada no Entregável 1.

Lembre-se de que utilizamos o objeto `pnad` para armazenar os dados da pesquisa.

Quando o objeto é importado com `design = TRUE`, ele contém informações sobre o desenho amostral da pesquisa, além das variáveis utilizadas na análise.

Nos exemplos a seguir, consideramos que o objeto `pnad` já foi criado na sessão R.

5.5.1 Visualizando os nomes das variáveis

O primeiro passo é utilizar a função `names()`.

```
1 names(pnad$variables)
```

Esse comando apresenta os nomes das variáveis disponíveis na base.

Entendendo o código:

- `pnad`: objeto que contém os dados importados.
- `$variables`: acessa as variáveis armazenadas no objeto.
- `names()`: retorna os nomes das colunas.

Como a PNAD possui muitas variáveis, a lista apresentada pode ser extensa.

5.5.2 Visualizando apenas as primeiras variáveis

Podemos utilizar a função `head()` para mostrar somente os primeiros nomes.

```
1 head(names(pnad$variables), 20)
```

Nesse exemplo, o argumento `20` determina que serão mostrados os primeiros vinte nomes.

Esse procedimento facilita uma inspeção inicial da estrutura da base.

5.5.3 Procurando uma variável específica

Se quisermos verificar se a variável de idade está presente, podemos utilizar o operador `%in%`.

```r
"V2009" %in% names(pnad$variables)
```

O comando verifica se o nome `V2009` está entre os nomes das variáveis.

Se o resultado for:

`TRUE`

Isso significa que a variável foi encontrada.

Se o resultado for:

`FALSE`

Isso significa que ela não está presente com esse nome no objeto consultado.

5.5.4 Verificando todas as variáveis selecionadas

Em vez de procurar uma variável por vez, podemos criar uma lista com todos os códigos necessários.

```r
variaveis_escolhidas <- c(
  "V2001",
  "V2005",
  "V2007",
  "V2009",
  "V2010" ,
  "VD3005",
  "VD4001" ,
  "VD4002" ,
  "VD5001" ,
  "VD5002"
)

variaveis_escolhidas %in% names(pnad$variables)
```

Entendendo o código:

- `c()` reúne os nomes das variáveis em um vetor.
- `<-` atribui esse vetor ao objeto `variaveis_escolhidas`.
- `%in%` verifica se cada elemento aparece na lista de nomes da base.

O R retornará valores `TRUE` ou `FALSE`, permitindo identificar quais códigos foram encontrados.

5.5.5 Identificando quais variáveis estão ausentes

Também podemos descobrir quais variáveis escolhidas não foram encontradas.

```
setdiff(
  variaveis_escolhidas,
  names(pnad$variables)
)
```

A função `setdiff()` identifica os elementos da primeira lista que não aparecem na segunda.

Se o resultado for:

`character(0)`

Isso significa que nenhum dos códigos selecionados está ausente da lista de nomes.

Caso apareçam códigos, será necessário verificar a documentação e a disponibilidade das variáveis na base utilizada.

5.5.6 Verificando os tipos de dados

Depois de localizar as variáveis, podemos consultar seus tipos no R.

```
sapply(
  pnad$variables[
    variaveis_escolhidas
  ],
  class
)
```

Observe especialmente a classe de `V2005`. Se ela aparecer como `factor` ou `character`, o filtro da pessoa responsável será `V2005 == "01"`; se for numérica, será `V2005 == 1`. Esse comando consulta a classe de cada variável selecionada.

Entre os tipos que podem aparecer estão:

- `numeric`: valores numéricos.
- `integer`: números inteiros.
- `character`: textos.
- `factor`: categorias representadas como fatores.

É importante distinguir o tipo de armazenamento no R do significado estatístico da variável.

Por exemplo, uma variável categórica pode ser armazenada por meio de códigos numéricos.

5.6 Conferindo nossa seleção

Ao longo desta aula, identificamos nove variáveis inicialmente relevantes para a análise da renda domiciliar.

Também aprendemos a utilizar funções do R para verificar quais códigos aparecem na base e consultar seus tipos.

Antes de continuar o projeto, é importante conferir:

- Se todos os códigos escolhidos estão presentes na PNAD utilizada.
- Se as descrições correspondem à documentação do IBGE.
- Se as variáveis são adequadas às perguntas da pesquisa.
- Se existem informações ausentes ou particularidades que precisam ser consideradas.

Essa conferência é importante para evitar problemas nas próximas etapas.

6 Renomeando as variáveis de forma padronizada e armazenando-as em uma base de dados para nossa pesquisa

6.1 Por que criar uma base de dados separada para nossa pesquisa?

As bases disponibilizadas pelo IBGE, como os microdados da PNAD Contínua, possuem uma grande quantidade de informações, muitas das quais podem não ter relação direta com o objetivo da pesquisa. Por isso, em vez de realizar todas as operações diretamente sobre a base original, recomenda-se criar uma cópia contendo somente as informações necessárias para o desenvolvimento do artigo.

Essa prática apresenta algumas vantagens:

- **Preservação dos dados originais:** mantém a base disponibilizada pelo IBGE intacta, permitindo retornar aos dados originais caso alguma transformação seja realizada incorretamente.

- **Organização:** concentra as informações relevantes em um único objeto, facilitando a localização e utilização das variáveis.

- **Eficiência:** reduz a quantidade de informações que o R precisa manipular, podendo melhorar o desempenho das operações.

- **Reprodutibilidade:** facilita a identificação das variáveis utilizadas e dos procedimentos realizados durante o tratamento dos dados.

É importante compreender que a nova base não representa uma alteração nos dados originais, mas uma versão reduzida e organizada, construída especificamente para responder à pergunta de pesquisa.

6.2 Por que padronizar os nomes das variáveis?

Os nomes utilizados pelo IBGE seguem uma estrutura própria de identificação. Embora sejam importantes para manter a organização dos microdados, códigos como V2009, V2007 e V2005 não permitem identificar imediatamente o conteúdo de cada variável. Ao substituir esses códigos por nomes mais intuitivos, facilitamos a leitura e a interpretação dos comandos utilizados no R. Por exemplo, imagine um código que calcula a média de idade dos indivíduos:

```
mean(pnad$V2009, na.rm = TRUE)
```

Embora o comando esteja correto, é necessário consultar o dicionário da PNAD para identificar o significado de V2009. Após a padronização, o mesmo comando pode ser escrito da seguinte maneira:

```
mean(base_trabalho$idade, na.rm = TRUE)
```

A segunda versão é mais intuitiva, pois permite compreender imediatamente qual informação está sendo utilizada. Além disso, a padronização evita inconsistências na escrita dos nomes, facilita o trabalho em equipe e torna o código mais acessível para outros pesquisadores.

6.2.1 Qual padrão de nomenclatura utilizar?

Não existe uma única convenção obrigatória para nomear variáveis no R. Entretanto, é recomendável escolher um padrão e utilizá-lo durante todo o desenvolvimento da pesquisa. Para trabalhos acadêmicos que envolvem manipulação e análise de dados, recomendamos o padrão `snake_case`. Nesse formato, os nomes são escritos em letras minúsculas, sem acentos, sem espaços e com palavras separadas por `underline (_)`.

Evitar	Recomendado
`V2009`	`idade`
`SEXO`	`sexo`
`Renda Familia`	`renda_familiar`
`IdadeMorador`	`idade_morador`
`RendaPerCapita`	`renda_per_capita`
`Escolaridade`	`escolaridade`

Padrão recomendado: snake_case

6.3 Renomeando as variáveis para a base de dados da pesquisa

Vamos criar uma nova base de dados contendo apenas as variáveis que serão utilizadas na pesquisa, já atribuindo nomes padronizados durante a seleção. Essa abordagem é mais adequada porque combina duas etapas importantes do tratamento dos dados: a seleção das variáveis relevantes (data selection) e a padronização da nomenclatura (data cleaning).

Considerando que o objetivo de um artigo é relacionado a uma pergunta específica, a base original da PNAD provavelmente conterá muitas variáveis que não serão utilizadas diretamente na análise. Contribuindo para a redução de erros, pois diminui a possibilidade de utilizar acidentalmente variáveis inadequadas durante as análises.

6.3.1 Como renomear as variáveis com o R na prática?

Vamos considerar algumas variáveis que poderiam ser utilizadas no estudo:

Variável PNAD	Descrição	Nome padronizado
`V2009`	Idade do morador	`idade`
`V2007`	Sexo	`sexo`
`VD5002`	Rendimento domiciliar per capita	`renda_per_capita`

O exemplo abaixo utiliza a função `select()` do pacote `dplyr`, que permite selecionar e renomear variáveis simultaneamente.
Observação: Considerando que o pacote `dplyr` já está instalado no R. Caso ainda não esteja instalado utilize o comando `install.packages("dplyr")` uma vez.

```r
# Carregar o pacote
library(dplyr)

# Criar uma base específica para a pesquisa
base_trabalho <- pnad %>%
  select(
    idade = V2009,
    sexo = V2007,
    renda_per_capita = VD5002
  )
```

Nesse procedimento, o objeto pnad permanece inalterado, enquanto base_trabalho contém somente as quatro variáveis selecionadas, já com seus respectivos nomes padronizados. **Atenção:** as variáveis apresentadas são exemplos para demonstrar o procedimento. A escolha definitiva deve considerar o dicionário da edição da PNAD utilizada e, principalmente, qual tema será abordado em seu projeto.

6.4 Resumo: Expandindo para nossa pesquisa e o resultado da padronização.

Utilizando da relação de variáveis relevante para nossa pesquisa construimos nossa base de dados, utilizando da padronização no padrão `snake_case`. Para isso, no R:

```
library(dplyr)

base_trabalho <- pnad %>%
  select(
    uf = UF,
    numero_moradores = V2001,
    condicao_domicilio = V2005,
    sexo = V2007,
    idade = V2009,
    cor_ou_raça = V2010 ,
    anos_estudo = VD3005,
    condicao_forca_trabalho = VD4001 ,
    condicao_ocupacao = VD4002 ,
    rendimento_domiciliar = VD5001,
    rendimento_per_capita = VD5002,
  )
```

Agora temos a base de dados `base_trabalho`, que contém as informações relevantes para seguirmos com o desenvolvimento da pesquisa.

Para termos maior praticidade a tabela a seguir apresenta a correspondência entre os códigos originais das variáveis, as informações que representam e os respectivos nomes que serão utilizados ao longo do desenvolvimento da pesquisa.

6.5 Tabela de correspondência das variáveis

Código original	Informação investigada	Nome padronizado
`UF`	Unidade da Federação	`uf`
`V2001`	Número de pessoas no domicílio	`numero_moradores`
`V2003`	Número de ordem do morador	`ordem_morador`
`V2005`	Condição no domicílio	`condicao_domicilio`
`V2007`	Sexo do morador	`sexo`
`V2009`	Idade	`idade`

Código original	Informação investigada	Nome padronizado
VD3005	Anos de estudo	anos_estudo
VD4001	Condição em relação à força de trabalho	condicao_forca_trabalho
VD4002	Condição de ocupação (fora da força de trabalho)	condicao_ocupacao
VD5001	Indicador de rendimento domiciliar	rendimento_domiciliar
VD5002	Indicador de rendimento domiciliar per capita	rendimento_per_capita

Fonte: Elaboração própria, com base no dicionário de variáveis da PNAD Contínua/IBGE.

7 Dicionário das variáveis selecionadas

A tabela consolida os códigos selecionados na seção de renomeação para a PNAD Contínua anual de 2024. O tipo indica a classificação estatística da variável. Os códigos iniciados por `VD` identificam variáveis derivadas disponibilizadas pelo próprio IBGE.

Código original	Descrição	Tipo da variável
`UF`	Unidade da Federação.	Qualitativa nominal
`V2001`	Número de pessoas no domicílio.	Quantitativa discreta
`V2003`	Número de ordem do morador: identificador do registro individual no domicílio.	Qualitativa nominal (identificador)
`V2005`	Condição do morador no domicílio, em relação à pessoa responsável.	Qualitativa nominal
`V2007`	Sexo do morador.	Qualitativa nominal
`V2009`	Idade do morador na data de referência, em anos completos.	Quantitativa discreta
`VD3005`	Anos de estudo das pessoas de 5 anos ou mais de idade, padronizados para o ensino fundamental com duração de 9 anos; categorias de “sem instrução e menos de 1 ano de estudo” a “16 anos ou mais de estudo”.	Qualitativa ordinal (categorias ordenadas de anos de estudo)

Código original	Descrição	Tipo da variável
VD5001	Rendimento efetivo domiciliar, em R, *excluindorendimentosemcarto/tquetetransporteoualimentaoerendimentos* excluindo rendimentos em cartão/tíquete transporte ou alimentação e rendimentos de pensionistas, empregados domésticos e parentes de empregados domésticos.	Quantitativa contínua
VD5004	Rendimento efetivo domiciliar, em R, *incluindorendimentosemcarto/tquetetransporteoualimentaoeexcluindoren* incluindo rendimentos em cartão/tíquete transporte ou alimentação e excluindo rendimentos de pensionistas, empregados domésticos e parentes de empregados domésticos.	Quantitativa contínua

Part III

ENTREGAVEL 3

8

O broder vai delegar tarefa pro davi e ele ira desenvolver aqui

9

10

O broder vai delegar tarefa pro joão pedro e ele ira desenvolver aqui

11

O broder vai delegar tarefa pro lucas e ele ira desenvolver aqui

12

13