E-book de Introdução ao R

William Cordeiro, Lucas de Freitas...

Table of contents

Apresentação 5

I ENTREGAVEL 1 6

1 Entregável 1 — Importação da PNAD Contínua no Positron 7

2 Importação da PNAD Contínua no Positron 8
2.1 Etapa 1 — Instalar o pacote . . . 8
2.2 Etapa 2 — Carregar o pacote . . . 9

3 Etapa 3 — Definir os parâmetros da consulta 10
3.1 Etapa 4 — Baixar e importar a PNAD Contínua . . . 10
3.2 Etapa 5 — Conferir o resultado . . . 11
3.2.1 1. Identificar o tipo de objeto — `class()` . . . 11
3.2.2 2. Consultar o resumo do objeto — `summary()` . . . 12
3.2.3 3. Conhecer os nomes das variáveis — `names()` . . . 12
3.2.4 4. Verificar o tamanho da base — `dim()` . . . 13
3.2.5 5. Visualizar os primeiros registros — `head()` . . . 13
3.2.6 Conclusão . . . 14
3.3 Encerramento . . . 14

II ENTREGAVEL 2 15

4 Introdução e interpretação das variáveis: Conhecendo os microdados da PNAD Contínua 16
4.1 O que são variáveis e por que precisamos interpretá-las? . . . 16
4.2 O que é um dicionário de variáveis? . . . 16
4.2.1 Como ler um dicionário de variáveis? . . . 17
4.3 Tipos de variáveis e unidades de medida . . . 17
4.3.1 Variáveis qualitativas . . . 18
4.3.2 Variáveis quantitativas . . . 18
4.3.3 Unidades de medida . . . 18
4.4 Aplicando os conceitos à nossa pesquisa . . . 19

4.5 Explorando as variáveis no R . . . 20
4.5.1 Passo 2 — Consultar uma variável específica . . . 20
4.5.2 Passo 3 — Consultar os códigos e suas categorias . . . 21
4.5.3 Passo 4 — Identificar a pessoa responsável pelo domicílio . . . 21
4.6 Cuidados metodológicos antes de prosseguir . . . 22
4.6.1 Unidade de observação . . . 22
4.6.2 Valores ausentes e códigos especiais . . . 22
4.6.3 Rendimentos nominais e reais . . . 22
4.6.4 Pesos amostrais . . . 22

5 Seleção das variáveis para a análise de renda 23
5.1 1. Introdução . . . 23
5.2 2. O que queremos investigar? . . . 23
5.3 3. Escolhendo as variáveis necessárias . . . 24
5.4 4. Por que escolhemos cada variável? . . . 25
5.4.1 4.1. Rendimento do trabalho — VD4019 . . . 25
5.4.2 4.2. Sexo — V2007 . . . 25
5.4.3 4.3. Idade — V2009 . . . 25
5.4.4 4.4. Cor ou raça — V2010 . . . 25
5.4.5 4.5. Escolaridade — VD3004 . . . 26
5.4.6 4.6. Unidade da Federação — UF . . . 26
5.4.7 4.7. Condição de ocupação — VD4002 . . . 26
5.5 5. Como localizar as variáveis no R? . . . 26
5.5.1 5.1. Visualizando os nomes das variáveis . . . 27
5.5.2 5.2. Visualizando apenas as primeiras variáveis . . . 27
5.5.3 5.3. Procurando uma variável específica . . . 27
5.5.4 5.4. Verificando todas as variáveis selecionadas . . . 28
5.5.5 5.5. Identificando quais variáveis estão ausentes . . . 28
5.5.6 5.6. Verificando os tipos de dados . . . 29
5.6 6. Conferindo nossa seleção . . . 29
5.7 7. Conclusão . . . 30

6 Renomeando as variáveis de forma padronizada e armazenando-as em uma base de dados para nossa pesquisa 31
6.1 Por que criar uma base de dados separada para nossa pesquisa? . . . 31
6.2 Por que padronizar os nomes das variáveis? . . . 31
6.3 Qual padrão de nomenclatura utilizar? . . . 32

7 Renomeando as variáveis para a base de dados da pesquisa 33
7.1 Como renomear as variáveis com o R na prática? . . . 33

8 Resumo: Expandindo para nossa pesquisa e o resultado da padronização. 35
8.1 Tabela de correspondência das variáveis . . . 35

9 Dicionário das variáveis selecionadas 37

III ENTREGAVEL 3 39

Apresentação

Bem-vindo ao nosso e-book de introdução à linguagem R.

Este material foi desenvolvido em colaboração para ensinar programação em R, desde os conceitos básicos.

Part I

ENTREGAVEL 1

1 Entregável 1 — Importação da PNAD Contínua no Positron

2 Importação da PNAD Contínua no Positron

Neste entregável, vamos aprender a instalar e carregar o pacote `PNADcIBGE`, selecionar o ano e o trimestre de interesse, importar os dados da PNAD Contínua e verificar o resultado no R usando o Positron.

Exemplo didático: primeiro trimestre de 2024.

Pré-requisitos: R e Positron instalados.

2.1 Etapa 1 — Instalar o pacote

Para começar, precisamos instalar o pacote `PNADcIBGE`, que permite acessar os microdados da PNAD Contínua diretamente pelo R.

```
1 install.packages("PNADcIBGE")
```

Mas de onde vem esse pacote?

No R, existem pacotes desenvolvidos por pesquisadores e programadores que acrescentam funcionalidades à linguagem. Muitos deles ficam disponíveis no **CRAN (Comprehensive R Archive Network)**, um repositório oficial de distribuição de pacotes do R, ou seja quando instalamos o R ele vem com a capacidade de acessar o CRAN pela internet.

O pacote `PNADcIBGE` foi desenvolvido para facilitar o acesso e o tratamento dos dados da PNAD Contínua, disponibilizados pelo IBGE, por isso, não precisamos acessar manualmente o site do IBGE para instalar esse pacote. O próprio R consegue encontrá-lo e instalá-lo pelo comando que usamos acima.

Entendendo o código:

- `install.packages()` é uma função do R utilizada para instalar pacotes.
- `"PNADcIBGE"` é o nome do pacote que queremos instalar.
- Ao executar o comando, o R acessa um repositório de pacotes configurado, como o CRAN, e realiza a instalação.

Dica: execute esse comando no console R do Positron apenas uma vez, pois não é necessário reinstalar o pacote a cada nova sessão.

Caso queira **salvar um código e, ao mesmo tempo, testá-lo**, escreva-o diretamente no editor de código do positron. Em seguida, selecione o código desejado e pressione **Ctrl + Enter**.

O Positron enviará o trecho selecionado para o console R, onde ele será executado. Dessa forma, você poderá testar comandos específicos sem precisar executar novamente todos os códigos que já escreveu, mantendo suas anotações salvas e organizadas.

2.2 Etapa 2 — Carregar o pacote

Em uma nova sessão do R, carregue o pacote instalado com `library()`.

```
1 library(PNADcIBGE)
```

A função library() carrega um pacote previamente instalado, disponibilizando suas funções para utilização na sessão atual do R. Diferentemente de install.packages(), ela não realiza uma nova instalação.

Podemos pensar no install.packages() como um "instalador de um jogo" e no library() como "abrir o jogo para começar a jogar".

3 Etapa 3 — Definir os parâmetros da consulta

Antes de buscar os dados, defina o ano e o trimestre que deseja consultar. No R, o operador <- atribui um valor a um objeto.

```
ano <- 2024
trimestre <- 1  # Trimestres disponíveis: 1, 2, 3 ou 4
```

Neste exemplo, estamos solicitando o **primeiro trimestre de 2024**. Para consultar outro período, modifique esses dois valores.

3.1 Etapa 4 — Baixar e importar a PNAD Contínua

Agora que definimos o ano e o trimestre, vamos utilizar a função get_pnadc() para baixar os microdados da PNAD Contínua diretamente do IBGE e importá-los para o R.

```
pnad <- PNADcIBGE::get_pnadc(
  year = ano,
  quarter = trimestre,
  design = TRUE
)
```

Entendendo cada parte do código:

pnad <-: cria um objeto chamado pnad, no qual serão armazenados os dados importados.

PNADcIBGE::: indica que estamos utilizando uma função do pacote PNADcIBGE. O operador :: permite acessar essa função sem precisar carregar o pacote com library().

get_pnadc(): é a função responsável por obter e importar os dados da PNAD Contínua.

year = ano: define o ano da pesquisa. Como anteriormente escrevemos ano <- 2024, serão utilizados os dados de 2024.

quarter = trimestre: define o trimestre. Como escrevemos trimestre <- 1, será utilizado o primeiro trimestre.

design = TRUE: solicita que os dados sejam organizados considerando o desenho amostral da PNAD, incluindo informações como pesos amostrais, importantes para produzir estimativas estatísticas adequadas à pesquisa.

Atenção: a primeira execução pode demorar, pois envolve o download e o processamento dos microdados. É necessário ter conexão com a internet e espaço disponível no computador.

3.2 Etapa 5 — Conferir o resultado

Após importar os dados da PNAD Contínua, precisamos verificar se a importação ocorreu corretamente e entender como as informações estão organizadas. Para isso, utilizaremos cinco comandos do R.

3.2.1 1. Identificar o tipo de objeto — `class()`

```
class(pnad)
```

A função `class()` identifica a classe de um objeto no R, determinando como ele está estruturado e quais métodos podem ser utilizados com ele.

Por exemplo, um objeto pode ser da classe `data.frame` (tabela de dados), `matrix` (matriz) ou `lm` (modelo de regressão).

Saída esperada:

```
[1] "svyrep.design"
```

No nosso caso, essa classe indica que os dados foram organizados em um objeto de desenho amostral com pesos de replicação, adequado para análises estatísticas que consideram a amostragem da PNAD.

Por que é importante? Porque permite verificar se o objeto foi criado no formato esperado e quais funções poderão ser utilizadas nas análises.

3.2.2 2. Consultar o resumo do objeto — `summary()`

```
summary(pnad)
```

A função `summary()` apresenta um resumo do objeto, mas as informações exibidas dependem de sua classe.

Por exemplo, para uma variável numérica, pode apresentar média, mediana, mínimo e máximo. Já para nosso objeto `pnad`, apresenta informações sobre o desenho amostral.

Exemplo ilustrativo simplificado de saída:

```
Call: PNADcIBGE::get_pnadc(...)

Survey design with replicate weights

Number of observations: ...
Replicate weights: ...
```

O formato e os detalhes efetivos podem ser diferentes. Os pontos representam informações que dependem da base importada.

Por que é importante? Porque ajuda a conferir a estrutura amostral utilizada, incluindo informações relacionadas aos pesos e às réplicas. Esse comando não calcula automaticamente a renda média da população.

3.2.3 3. Conhecer os nomes das variáveis — `names()`

```
names(pnad$variables)[1:20]
```

A função `names()` mostra os nomes das variáveis da base.

- `pnad$variables`: acessa a tabela de dados armazenada no objeto.
- `[1:20]`: seleciona os primeiros 20 nomes.

Exemplo ilustrativo de saída:

```
[1] "Ano"      "Trimestre" "UF"
[4] "UPA"      "Estrato"   "V1008"
[7] "V1014"    "V1022"     "V1023"
...
```

Essa lista é apenas um exemplo: os primeiros 20 nomes e sua ordem devem ser conferidos no seu console.

Por que é importante? Porque permite conhecer as variáveis disponíveis e identificar os códigos que serão utilizados no estudo.

3.2.4 4. Verificar o tamanho da base — `dim()`

```
dim(pnad$variables)
```

A função `dim()` informa o tamanho da tabela, retornando a quantidade de linhas e colunas.

Exemplo ilustrativo de saída:

```
[1] 480000  430
```

Nesse exemplo fictício:

- `480000`: quantidade de registros (linhas).
- `430`: quantidade de variáveis (colunas).

Os números reais dependerão da base importada.

Por que é importante? Porque permite conhecer o tamanho da base e verificar se existem observações e variáveis disponíveis para trabalhar.

3.2.5 5. Visualizar os primeiros registros — `head()`

```
head(pnad$variables)
```

A função `head()` apresenta, por padrão, as seis primeiras linhas da tabela, permitindo observar como os dados estão organizados.

Exemplo ilustrativo de saída (colunas selecionadas):

```
  UF V2007 V2009 V2010
1 35     1    25     1
2 35     2    32     4
3 33     1    41     2
4 33     2    28     1
5 31     1    54     4
6 31     2    37     2
```

Nesse exemplo fictício, cada linha representa um registro e cada coluna corresponde a uma variável. Os números podem representar quantidades ou códigos de categorias, dependendo da variável.

Por que é importante? Porque permite visualizar a organização dos dados, identificar possíveis valores ausentes (`NA`) e entender como as informações aparecem antes das análises.

3.2.6 Conclusão

Com esses cinco comandos, conseguimos verificar a classe do objeto, consultar sua estrutura amostral, identificar as variáveis, conhecer as dimensões da base e visualizar os primeiros registros.

Atenção: os resultados apresentados são exemplos didáticos. Ao executar os comandos no Positron, o leitor poderá encontrar valores e formatos diferentes, conforme os dados importados.

Essa conferência inicial nos prepara para o próximo capítulo, no qual aprenderemos a selecionar e interpretar as variáveis da PNAD Contínua.

3.3 Encerramento

Neste capítulo, você viu o fluxo básico de importação da PNAD Contínua no Positron: **instalar o pacote → carregá-lo → definir o período → importar → conferir os dados**. Os exemplos usam o primeiro trimestre de 2024; o procedimento pode ser adaptado para outros trimestres.

Part II

ENTREGAVEL 2

4 Introdução e interpretação das variáveis: Conhecendo os microdados da PNAD Contínua

4.1 O que são variáveis e por que precisamos interpretá-las?

Antes de iniciar qualquer análise estatística, é necessário compreender quais informações estão disponíveis na base de dados e o que cada uma delas representa.

Uma variável é uma característica observada para cada unidade de análise de uma pesquisa. Na PNAD Contínua, por exemplo, podemos encontrar informações sobre idade, escolaridade, rendimento, condição de ocupação e características dos domicílios.

Em uma pesquisa sobre diferenças de renda entre famílias chefiadas por homens e mulheres, algumas perguntas orientam a escolha das variáveis:

- Qual é a renda do domicílio?
- Quem é considerado responsável pelo domicílio?
- Em qual região do Brasil o domicílio está localizado?
- Qual é a escolaridade dos moradores?
- Quantas pessoas compõem o domicílio?

Cada pergunta precisa ser associada a uma ou mais variáveis disponíveis na base de dados.

Uma observação importante: não basta encontrar uma variável com um nome aparentemente adequado. É necessário verificar sua definição, população de referência, período de coleta, categorias de resposta e unidade de medida.

4.2 O que é um dicionário de variáveis?

Um dicionário de variáveis é um documento que descreve as informações presentes em uma base de dados. Ele funciona como um guia para compreender e utilizar corretamente cada variável.

Normalmente, apresenta informações como: Nome da variável, descrição, tipo de variável (numérica, categórica, textual), Categorias (valores ou respostas possíveis), unidade de medida e população de referência

Por exemplo, imagine que uma base apresente a variável V2009. Sem consultar a documentação, o pesquisador não sabe necessariamente o que esse código representa. Ao consultar o dicionário, descobre que se trata de uma informação sobre idade. Essa consulta permite compreender o significado dos dados e evita interpretações equivocadas.

Isso é importante pois:

- Evita confundir variáveis com nomes ou códigos semelhantes.
- Permite identificar quais informações são adequadas aos objetivos da pesquisa.
- Ajuda a reconhecer valores ausentes e categorias especiais.
- Facilita a interpretação dos resultados.
- Torna a análise reproduzível por outros pesquisadores.

4.2.1 Como ler um dicionário de variáveis?

Ao abrir o dicionário, você encontrará códigos que identificam as variáveis e suas respectivas descrições.

Código	Descrição
V2009	Idade do morador na data de referência
V2007	Sexo do morador
V2005	Condição no domicílio

Para interpretar corretamente essas informações, é necessário observar três elementos:

1. Código da variável: é o identificador utilizado no banco de dados e nos comandos do R.
2. Descrição: explica qual característica está sendo investigada.
3. Categorias ou valores possíveis: indicam como as respostas foram registradas.

Por exemplo, uma variável sobre sexo pode apresentar valores numéricos que representam categorias de resposta. O número não possui significado isoladamente: é a documentação que informa o que cada código representa.

4.3 Tipos de variáveis e unidades de medida

As variáveis podem assumir diferentes formatos, e reconhecer essas diferenças é essencial para escolher os procedimentos estatísticos adequados.

4.3.1 Variáveis qualitativas

Representam características ou categorias. Podem ser divididas em:

- Nominais: categorias sem uma ordem natural, como sexo, região geográfica e cor ou raça.
- Ordinais: categorias que apresentam uma ordem, como faixas de escolaridade ou classes de rendimento.

4.3.2 Variáveis quantitativas

Representam valores numéricos e podem ser divididas em:

- Discretas: assumem valores contáveis, como número de moradores no domicílio.
- Contínuas: podem assumir diferentes valores dentro de um intervalo, como rendimento mensal.

É importante não confundir o formato numérico de uma variável com seu significado estatístico. Uma variável que utiliza os números 1, 2, 3 e 4 para representar regiões brasileiras continua sendo qualitativa, pois os números são apenas códigos de identificação.

4.3.3 Unidades de medida

Também é necessário identificar a unidade em que cada característica é registrada.

Informação	Unidade de medida
Idade	Anos
Escolaridade	Anos de estudo ou nível de instrução
Rendimento	Reais (R$)
Número de moradores	Pessoas
Região	Categoria geográfica

Essa distinção é especialmente importante na análise de renda. Um rendimento mensal domiciliar total não representa a mesma coisa que um rendimento domiciliar per capita. O primeiro considera a renda total do domicílio; o segundo considera a renda em relação ao número de moradores, conforme a definição específica do indicador.

4.4 Aplicando os conceitos à nossa pesquisa

Agora que conhecemos os conceitos básicos, podemos identificar as variáveis necessárias para investigar diferenças de renda entre domicílios chefiados por homens e mulheres.

Para o nosso exercício, utilizaremos os microdados da PNAD Contínua de 2024, referentes à primeira visita domiciliar anual.

A seleção inicial de variáveis contempla:

Código	Informação investigada	Utilidade na pesquisa
UF	Unidade da Federação	Identificar a localização geográfica
V2001	Número de pessoas no domicílio	Analisar a composição domiciliar
V2003	Número de ordem do morador	Identificar registros individuais
V2005	Condição no domicílio	Identificar a pessoa responsável
V2007	Sexo do morador	Identificar o sexo da pessoa responsável
V2009	Idade	Caracterizar os moradores
VD3005	Anos de estudo	Investigar a escolaridade
VD5001	Indicador de rendimento domiciliar	Investigar a renda
VD5002	Indicador de rendimento domiciliar per capita	Investigar a renda por morador
VD5004	Indicador de rendimento domiciliar	Complementar a análise de renda
VD5005	Indicador de rendimento domiciliar per capita	Complementar a análise de renda

A tabela acima é uma seleção inicial de trabalho. As descrições completas de VD5001, VD5002, VD5004 e VD5005, inclusive a distinção entre rendimento efetivo e habitual e os critérios de inclusão de rendimentos, devem ser transcritas do dicionário específico da edição anual de 2024 antes da publicação do e-book. Não se deve tratar esses indicadores como equivalentes. Atenção: quem é considerado chefe do domicílio? Esse é um dos pontos metodológicos mais importantes da pesquisa.

A PNAD Contínua utiliza o conceito de pessoa responsável pelo domicílio. A variável V2005 identifica a relação de cada morador com essa pessoa.

Na documentação, o código 01 corresponde à pessoa responsável pelo domicílio. Assim, podemos identificar quem é responsável e, em seguida, consultar seu sexo por meio da variável V2007.

Isso significa que não devemos simplesmente classificar todos os moradores do sexo masculino como integrantes de domicílios chefiados por homens.

O procedimento correto é:

1. Identificar a pessoa responsável pelo domicílio.
2. Consultar o sexo dessa pessoa.
3. Classificar o domicílio de acordo com essa informação.

Outra ressalva conceitual: pessoa responsável pelo domicílio não é necessariamente sinônimo de chefe de família. Um domicílio pode conter mais de uma família. Portanto, é importante definir se a pesquisa pretende comparar domicílios ou famílias e manter essa unidade de análise ao longo do trabalho.

4.5 Explorando as variáveis no R

Até aqui, aprendemos a consultar a documentação. Agora vamos começar a relacionar essas informações com o banco de dados.

Como estamos utilizando o R, podemos verificar quais variáveis estão disponíveis e observar os valores registrados. ### Passo 1 — Carregar os dados No exemplo, consideramos que a base já foi carregada com o pacote PNADcIBGE, utilizando a função get_pnadc().

```r
# Visualizar a estrutura da base
str(dados_pnad)
```

```r
# Visualizar as primeiras observações
head(dados_pnad)
```

```r
# Consultar os nomes das variáveis
names(dados_pnad)
```

4.5.1 Passo 2 — Consultar uma variável específica

Vamos começar pela variável V2005, que identifica a condição do morador no domicílio.

```r
# Visualizar os valores registrados
table(dados_pnad$V2005, useNA = "ifany")
```

O comando table() apresenta a frequência de cada valor encontrado na variável.

O argumento useNA = “ifany” permite identificar se existem observações ausentes (NA).

4.5.2 Passo 3 — Consultar os códigos e suas categorias

Podemos utilizar os atributos da variável para verificar se os rótulos foram carregados junto com os dados:

```
# Consultar os atributos da variável
attributes(dados_pnad$V2005)
```

Se a variável possuir rótulos associados, eles poderão aparecer nos atributos.

Também podemos visualizar a distribuição de uma variável de interesse:

```
# Frequência por sexo
table(dados_pnad$V2007, useNA = "ifany")
```

Importante: a frequência dos códigos não substitui a consulta ao dicionário. É necessário verificar na documentação o significado de cada categoria antes de interpretar os resultados.

4.5.3 Passo 4 — Identificar a pessoa responsável pelo domicílio

Podemos utilizar a variável V2005 para identificar os registros correspondentes à pessoa responsável:

```
# Selecionar pessoas responsáveis
responsaveis <- dados_pnad |>
  dplyr::filter(V2005 == "01")
```

O exemplo pressupõe que a variável esteja armazenada como texto. Se estiver numérica, utilize V2005 == 1. Antes de executar, confira a classe da variável com class(dados_pnad$V2005).

A partir dessa seleção, podemos consultar a variável V2007 para identificar o sexo das pessoas responsáveis.

Esse será um dos primeiros passos para construir nossa classificação de domicílios chefiados por homens e mulheres.

4.6 Cuidados metodológicos antes de prosseguir

Antes de iniciar as análises, precisamos considerar alguns aspectos importantes.

4.6.1 Unidade de observação

Os microdados da PNAD Contínua apresentam registros individuais dos moradores. Isso significa que um mesmo domicílio pode aparecer em várias linhas, uma para cada morador.

Se o objetivo é comparar rendimentos domiciliares, precisamos tomar cuidado para não contabilizar o mesmo domicílio várias vezes.

4.6.2 Valores ausentes e códigos especiais

Algumas variáveis podem apresentar códigos que representam situações específicas, como informação ignorada ou não aplicável. Esses códigos não devem ser interpretados automaticamente como valores reais.

4.6.3 Rendimentos nominais e reais

Os valores monetários precisam ser interpretados considerando o período de referência. Se o objetivo for comparar rendimentos de diferentes anos, será necessário realizar o deflacionamento.

4.6.4 Pesos amostrais

A PNAD Contínua é uma pesquisa por amostragem probabilística. Portanto, para produzir estimativas representativas da população brasileira, é necessário considerar os pesos amostrais e o desenho da pesquisa. Não basta calcular médias simples dos registros e tratá-las como estimativas populacionais.

5 Seleção das variáveis para a análise de renda

5.1 1. Introdução

No Entregável 1, aprendemos a importar os microdados da Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua), disponibilizados pelo Instituto Brasileiro de Geografia e Estatística (IBGE).

Agora que sabemos como obter os dados, precisamos entender quais informações são necessárias para realizar nossa análise.

A PNAD Contínua contém diversas variáveis relacionadas às características da população brasileira, como idade, sexo, cor ou raça, escolaridade, ocupação e rendimento.

Entretanto, nem todas essas variáveis serão utilizadas em nosso estudo.

Neste capítulo, aprenderemos a selecionar as variáveis mais relevantes para comparar a renda entre diferentes grupos da população.

Ao final desta aula, o leitor será capaz de:

- Identificar variáveis relevantes para uma análise de renda.
- Entender a importância de cada variável selecionada.
- Localizar essas variáveis dentro da base da PNAD utilizando R.
- Verificar quais informações estão disponíveis para futuras análises.

5.2 2. O que queremos investigar?

Antes de selecionar as variáveis, precisamos definir o objetivo da análise.

Neste exemplo, nosso objetivo será investigar como o rendimento do trabalho pode variar conforme características individuais e sociais.

Podemos formular algumas perguntas:

- Homens e mulheres apresentam diferenças de rendimento?
- O rendimento varia conforme a idade?
- Pessoas com diferentes níveis de escolaridade apresentam rendimentos distintos?
- Existem diferenças de rendimento entre grupos de cor ou raça?

- O rendimento varia entre estados brasileiros?

Para responder a essas perguntas, precisamos identificar as variáveis correspondentes na PNAD Contínua.

5.3 3. Escolhendo as variáveis necessárias

Uma variável representa uma característica ou informação registrada na base de dados.

Na PNAD Contínua, cada variável possui um código de identificação.

Por exemplo, a variável `V2009` representa a idade dos moradores.

Para nossa análise, selecionaremos inicialmente as seguintes variáveis:

Código	Variável	Finalidade
VD4019	Rendimento mensal habitual de todos os trabalhos	Analisar o rendimento do trabalho
V2007	Sexo	Comparar rendimentos entre homens e mulheres
V2009	Idade	Investigar diferenças de rendimento entre faixas etárias
V2010	Cor ou raça	Comparar rendimentos entre grupos de cor ou raça
VD3004	Nível de instrução	Investigar diferenças de rendimento por escolaridade
UF	Unidade da Federação	Comparar rendimentos entre estados
VD4002	Condição de ocupação	Identificar a condição de ocupação dos indivíduos

Essas variáveis constituem uma seleção inicial para o estudo.

A escolha definitiva deverá considerar a população que queremos analisar e a documentação correspondente ao período da pesquisa.

5.4 4. Por que escolhemos cada variável?

5.4.1 4.1. Rendimento do trabalho — VD4019

A variável `VD4019` corresponde ao rendimento mensal habitual de todos os trabalhos.

Ela será uma das principais variáveis de nossa análise, pois representa a informação de rendimento que queremos comparar entre diferentes grupos.

Por exemplo, poderemos investigar se o rendimento habitual do trabalho apresenta diferenças entre homens e mulheres.

É importante observar que essa variável se refere ao rendimento do trabalho, e não necessariamente à renda total recebida pelo indivíduo de todas as fontes.

5.4.2 4.2. Sexo — V2007

A variável `V2007` identifica o sexo registrado na pesquisa.

Ela permite organizar os indivíduos em grupos e, posteriormente, comparar seus rendimentos.

Por exemplo, poderemos estudar diferenças de rendimento entre homens e mulheres.

A comparação dos rendimentos entre os grupos permitirá descrever diferenças observadas nos dados, sem que isso, isoladamente, demonstre suas causas.

5.4.3 4.3. Idade — V2009

A variável `V2009` registra a idade do indivíduo em anos.

A idade é importante porque pessoas em diferentes momentos da vida podem apresentar características distintas de participação no mercado de trabalho.

Posteriormente, poderemos organizar as idades em faixas etárias para realizar comparações.

5.4.4 4.4. Cor ou raça — V2010

A variável `V2010` registra a cor ou raça declarada na pesquisa.

Ela possibilita comparar rendimentos entre diferentes grupos populacionais.

Essa informação é relevante para estudar desigualdades socioeconômicas, sempre considerando as limitações de uma análise descritiva.

5.4.5 4.5. Escolaridade — VD3004

A variável `VD3004` representa o nível de instrução.

A escolaridade é uma característica importante nas análises do mercado de trabalho, pois permite observar diferenças de rendimento entre indivíduos com diferentes níveis educacionais.

Podemos investigar, por exemplo, se pessoas com ensino superior completo apresentam rendimentos diferentes daqueles observados em outros níveis de instrução.

5.4.6 4.6. Unidade da Federação — UF

A variável `UF` identifica a Unidade da Federação correspondente ao registro.

Ela permite realizar comparações entre estados brasileiros.

Isso é importante porque os mercados de trabalho e as condições econômicas podem apresentar diferenças regionais.

5.4.7 4.7. Condição de ocupação — VD4002

A variável `VD4002` informa a condição de ocupação.

Essa informação ajuda a identificar a situação dos indivíduos em relação à ocupação, sendo importante para definir a população de interesse na análise de rendimentos do trabalho.

No Entregável 3, poderão ser estabelecidos os critérios de seleção dos registros para a análise.

5.5 5. Como localizar as variáveis no R?

Agora que escolhemos as variáveis necessárias, precisamos verificar se elas estão disponíveis na base importada no Entregável 1.

Lembre-se de que utilizamos o objeto `pnad` para armazenar os dados da pesquisa.

Quando o objeto é importado com `design = TRUE`, ele contém informações sobre o desenho amostral da pesquisa, além das variáveis utilizadas na análise.

Nos exemplos a seguir, consideramos que o objeto `pnad` já foi criado na sessão R.

5.5.1 5.1. Visualizando os nomes das variáveis

O primeiro passo é utilizar a função `names()`.

```
names(pnad$variables)
```

Esse comando apresenta os nomes das variáveis disponíveis na base.

Entendendo o código:

- `pnad`: objeto que contém os dados importados.
- `$variables`: acessa as variáveis armazenadas no objeto.
- `names()`: retorna os nomes das colunas.

Como a PNAD possui muitas variáveis, a lista apresentada pode ser extensa.

5.5.2 5.2. Visualizando apenas as primeiras variáveis

Podemos utilizar a função `head()` para mostrar somente os primeiros nomes.

```
head(names(pnad$variables), 20)
```

Nesse exemplo, o argumento `20` determina que serão mostrados os primeiros vinte nomes.

Esse procedimento facilita uma inspeção inicial da estrutura da base.

5.5.3 5.3. Procurando uma variável específica

Se quisermos verificar se a variável de idade está presente, podemos utilizar o operador `%in%`.

```
"V2009" %in% names(pnad$variables)
```

O comando verifica se o nome `V2009` está entre os nomes das variáveis.

Se o resultado for:

`TRUE`

Isso significa que a variável foi encontrada.

Se o resultado for:

`FALSE`

Isso significa que ela não está presente com esse nome no objeto consultado.

5.5.4 5.4. Verificando todas as variáveis selecionadas

Em vez de procurar uma variável por vez, podemos criar uma lista com todos os códigos necessários.

```
variaveis_escolhidas <- c(
  "VD4019",
  "V2007",
  "V2009",
  "V2010",
  "VD3004",
  "UF",
  "VD4002"
)

variaveis_escolhidas %in% names(pnad$variables)
```

Entendendo o código:

- `c()` reúne os nomes das variáveis em um vetor.
- `<-` atribui esse vetor ao objeto `variaveis_escolhidas`.
- `%in%` verifica se cada elemento aparece na lista de nomes da base.

O R retornará valores `TRUE` ou `FALSE`, permitindo identificar quais códigos foram encontrados.

5.5.5 5.5. Identificando quais variáveis estão ausentes

Também podemos descobrir quais variáveis escolhidas não foram encontradas.

```
setdiff(
  variaveis_escolhidas,
  names(pnad$variables)
)
```

A função `setdiff()` identifica os elementos da primeira lista que não aparecem na segunda.

Se o resultado for:

`character(0)`

Isso significa que nenhum dos códigos selecionados está ausente da lista de nomes.

Caso apareçam códigos, será necessário verificar a documentação e a disponibilidade das variáveis na base utilizada.

5.5.6 5.6. Verificando os tipos de dados

Depois de localizar as variáveis, podemos consultar seus tipos no R.

```
sapply(
  pnad$variables[
    variaveis_escolhidas
  ],
  class
)
```

Esse comando consulta a classe de cada variável selecionada.

Entre os tipos que podem aparecer estão:

- `numeric`: valores numéricos.
- `integer`: números inteiros.
- `character`: textos.
- `factor`: categorias representadas como fatores.

É importante distinguir o tipo de armazenamento no R do significado estatístico da variável.

Por exemplo, uma variável categórica pode ser armazenada por meio de códigos numéricos.

5.6 6. Conferindo nossa seleção

Ao longo desta aula, identificamos sete variáveis inicialmente relevantes para a análise de rendimentos.

Também aprendemos a utilizar funções do R para verificar quais códigos aparecem na base e consultar seus tipos.

Antes de continuar o projeto, é importante conferir:

- Se todos os códigos escolhidos estão presentes na PNAD utilizada.
- Se as descrições correspondem à documentação do IBGE.
- Se as variáveis são adequadas às perguntas da pesquisa.
- Se existem informações ausentes ou particularidades que precisam ser consideradas.

Essa conferência é importante para evitar problemas nas próximas etapas.

5.7 7. Conclusão

Neste capítulo, aprendemos a selecionar variáveis da PNAD Contínua para uma análise de renda entre diferentes grupos populacionais.

Primeiro, definimos as perguntas que queremos investigar.

Em seguida, escolhemos as variáveis que poderão ajudar a respondê-las e justificamos a importância de cada uma.

Por fim, apresentamos comandos em R para localizar os códigos e verificar sua disponibilidade na base importada.

A seleção e a identificação das variáveis constituem uma etapa essencial para organizar o banco de dados antes de realizar análises estatísticas.

Na próxima seção do Entregável 2, serão apresentadas técnicas para renomear e padronizar as variáveis, facilitando sua utilização nos códigos das etapas seguintes.

6 Renomeando as variáveis de forma padronizada e armazenando-as em uma base de dados para nossa pesquisa

6.1 Por que criar uma base de dados separada para nossa pesquisa?

As bases disponibilizadas pelo IBGE, como os microdados da PNAD Contínua, possuem uma grande quantidade de informações, muitas das quais podem não ter relação direta com o objetivo da pesquisa. Por isso, em vez de realizar todas as operações diretamente sobre a base original, recomenda-se criar uma cópia contendo somente as informações necessárias para o desenvolvimento do artigo.

Essa prática apresenta algumas vantagens:
- **Preservação dos dados originais:** mantém a base disponibilizada pelo IBGE intacta, permitindo retornar aos dados originais caso alguma transformação seja realizada incorretamente.
- **Organização:** concentra as informações relevantes em um único objeto, facilitando a localização e utilização das variáveis.
- **Eficiência:** reduz a quantidade de informações que o R precisa manipular, podendo melhorar o desempenho das operações.
- **Reprodutibilidade:** facilita a identificação das variáveis utilizadas e dos procedimentos realizados durante o tratamento dos dados.

É importante compreender que a nova base não representa uma alteração nos dados originais, mas uma versão reduzida e organizada, construída especificamente para responder à pergunta de pesquisa.

6.2 Por que padronizar os nomes das variáveis?

Os nomes utilizados pelo IBGE seguem uma estrutura própria de identificação. Embora sejam importantes para manter a organização dos microdados, códigos como V2009, V2007 e V2005 não permitem identificar imediatamente o conteúdo de cada variável. Ao substituir esses códigos por nomes mais intuitivos, facilitamos a leitura e a interpretação dos comandos utilizados no R. Por exemplo, imagine um código que calcula a média de idade dos indivíduos:

```r
mean(pnad$V2009, na.rm = TRUE)
```

Embora o comando esteja correto, é necessário consultar o dicionário da PNAD para identificar o significado de V2009. Após a padronização, o mesmo comando pode ser escrito da seguinte maneira:

```r
mean(base_trabalho$idade, na.rm = TRUE)
```

A segunda versão é mais intuitiva, pois permite compreender imediatamente qual informação está sendo utilizada. Além disso, a padronização evita inconsistências na escrita dos nomes, facilita o trabalho em equipe e torna o código mais acessível para outros pesquisadores.

6.3 Qual padrão de nomenclatura utilizar?

Não existe uma única convenção obrigatória para nomear variáveis no R. Entretanto, é recomendável escolher um padrão e utilizá-lo durante todo o desenvolvimento da pesquisa. Para trabalhos acadêmicos que envolvem manipulação e análise de dados, recomendamos o padrão `snake_case`. Nesse formato, os nomes são escritos em letras minúsculas, sem acentos, sem espaços e com palavras separadas por `underline (_)`.

Evitar	Recomendado
`V2009`	`idade`
`SEXO`	`sexo`
`Renda Familia`	`renda_familiar`
`IdadeMorador`	`idade_morador`
`RendaPerCapita`	`renda_per_capita`
`Escolaridade`	`escolaridade`

Padrão recomendado: snake_case

7 Renomeando as variáveis para a base de dados da pesquisa

Vamos criar uma nova base de dados contendo apenas as variáveis que serão utilizadas na pesquisa, já atribuindo nomes padronizados durante a seleção. Essa abordagem é mais adequada porque combina duas etapas importantes do tratamento dos dados: a seleção das variáveis relevantes (data selection) e a padronização da nomenclatura (data cleaning).

Considerando que o objetivo de um artigo é relacionado a uma pergunta específica, a base original da PNAD provavelmente conterá muitas variáveis que não serão utilizadas diretamente na análise. Contribuindo para a redução de erros, pois diminui a possibilidade de utilizar acidentalmente variáveis inadequadas durante as análises.

7.1 Como renomear as variáveis com o R na prática?

Vamos considerar algumas variáveis que poderiam ser utilizadas no estudo:

Variável PNAD	Descrição	Nome padronizado
`V2009`	Idade do morador	`idade`
`V2007`	Sexo	`sexo`
`V2005`	Condição no domicílio	`condicao_domicilio`
`VD5002`	Rendimento domiciliar per capita	`renda_per_capita`

O exemplo abaixo utiliza a função `select()` do pacote `dplyr`, que permite selecionar e renomear variáveis simultaneamente.
Observação: Considerando que o pacote `dplyr` já está instalado no R. Caso ainda não esteja instalado utilize o comando `install.packages("dplyr")` uma vez.

```
# Carregar o pacote
library(dplyr)

# Criar uma base específica para a pesquisa
base_trabalho <- pnad %>%
  select(
```

```
    idade = V2009,
    sexo = V2007,
    condicao_domicilio = V2005,
    renda_per_capita = VD5002
  )
```

Nesse procedimento, o objeto pnad permanece inalterado, enquanto base_trabalho contém somente as quatro variáveis selecionadas, já com seus respectivos nomes padronizados. **Atenção:** as variáveis apresentadas são exemplos para demonstrar o procedimento. A escolha definitiva deve considerar o dicionário da edição da PNAD utilizada e, principalmente, qual tema será abordado em seu projeto.

8 Resumo: Expandindo para nossa pesquisa e o resultado da padronização.

Utilizando da relação de variáveis relevante para nossa pesquisa construimos nossa base de dados, utilizando da padronização no padrão `snake_case`. Para isso, no R:

```
library(dplyr)

base_trabalho <- pnad %>%
  select(
    uf = UF,
    numero_moradores = V2001,
    ordem_morador = V2003,
    condicao_domicilio = V2005,
    sexo = V2007,
    idade = V2009,
    anos_estudo = VD3005,
    rendimento_domiciliar = VD5001,
    rendimento_per_capita = VD5002,
    rendimento_domiciliar_2 = VD5004,
    rendimento_per_capita_2 = VD5005
  )
```

Agora temos a base de dados `base_trabalho`, que contém as informações relevantes para seguirmos com o desenvolvimento da pesquisa.

Para termos maior praticidade a tabela a seguir apresenta a correspondência entre os códigos originais das variáveis, as informações que representam e os respectivos nomes que serão utilizados ao longo do desenvolvimento da pesquisa.

8.1 Tabela de correspondência das variáveis

Código original	Informação investigada	Nome padronizado
UF	Unidade da Federação	uf
V2001	Número de pessoas no domicílio	numero_moradores
V2003	Número de ordem do morador	ordem_morador
V2005	Condição no domicílio	condicao_domicilio
V2007	Sexo do morador	sexo
V2009	Idade	idade
VD3005	Anos de estudo	anos_estudo
VD5001	Indicador de rendimento domiciliar	rendimento_domiciliar
VD5002	Indicador de rendimento domiciliar per capita	rendimento_per_capita
VD5004	Indicador de rendimento domiciliar	rendimento_domiciliar_2
VD5005	Indicador de rendimento domiciliar per capita	rendimento_per_capita_2

Fonte: Elaboração própria, com base no dicionário de variáveis da PNAD Contínua/IBGE.

9 Dicionário das variáveis selecionadas

A tabela consolida os códigos selecionados na seção de renomeação para a PNAD Contínua anual de 2024. O tipo indica a classificação estatística da variável. Os códigos iniciados por `VD` identificam variáveis derivadas disponibilizadas pelo próprio IBGE.

Código original	Descrição	Tipo da variável
`UF`	Unidade da Federação.	Qualitativa nominal
`V2001`	Número de pessoas no domicílio.	Quantitativa discreta
`V2003`	Número de ordem do morador: identificador do registro individual no domicílio.	Qualitativa nominal (identificador)
`V2005`	Condição do morador no domicílio, em relação à pessoa responsável.	Qualitativa nominal
`V2007`	Sexo do morador.	Qualitativa nominal
`V2009`	Idade do morador na data de referência, em anos completos.	Quantitativa discreta
`VD3005`	Anos de estudo das pessoas de 5 anos ou mais de idade, padronizados para o ensino fundamental com duração de 9 anos; categorias de “sem instrução e menos de 1 ano de estudo” a “16 anos ou mais de estudo”.	Qualitativa ordinal (categorias ordenadas de anos de estudo)

Código original	Descrição	Tipo da variável
VD5001	Rendimento efetivo domiciliar, em R, *excluindorendimentosemcarto/tquetetransporteoualimentaoerendimentos* excluindo rendimentos em cartão/tíquete transporte ou alimentação e rendimentos de pensionistas, empregados domésticos e parentes de empregados domésticos.	Quantitativa contínua
VD5004	Rendimento efetivo domiciliar, em R, *incluindorendimentosemcarto/tquetetransporteoualimentaoeexcluindoren* incluindo rendimentos em cartão/tíquete transporte ou alimentação e excluindo rendimentos de pensionistas, empregados domésticos e parentes de empregados domésticos.	Quantitativa contínua

Part III

ENTREGAVEL 3

10

O broder vai delegar tarefa pro davi e ele ira desenvolver aqui

11

12

O broder vai delegar tarefa pro joão pedro e ele ira desenvolver aqui

13

O broder vai delegar tarefa pro lucas e ele ira desenvolver aqui

14

15